AI 设计工具评测 Benchmark：面向企业场景的方法论框架与实证研究

版本：v1.0（Round 1 冻结版）｜**发布时间**：2026-04｜**作者**：刘三觉（独立评测研究者）

数据说明：本报告基于 2026 年 3-4 月间对 3 款公开 AI 设计工具的双盲横向评测。评测以独立研究者身份进行，不代表任何机构立场，结论仅供参考。

摘要

本文提出并验证一套面向企业级 AI 设计工具的系统性评测框架——**AI 设计工具 Benchmark（ADB）**。

现有 AI 工具评测多聚焦于通用图像生成质量，难以反映 AI 设计工具在真实企业设计任务中的综合表现。本文从"设计任务的三大核心特征"出发，推导出双层指标体系（客观底线标准 + 主观高线标准），设计了双轨评测制度——轨道一：单图多维打分，轨道二：SbS（Side-by-Side）双盲图片排序，并给出可复现的结果聚合算法与置信度判定机制。

基于上述框架，作者在 7 个企业级设计场景（logo 设计、IP 形象设计、徽章奖杯设计、商品海报设计、商品图片美化、线上营销活动设计、线下推广物料设计）中，对 Lovart、即梦、Roboneo 三款公开 AI 设计工具进行了 SbS 双盲横评，共涉及 115 个设计任务、10 名评测员、33 道评测题。

主要发现：Lovart 在 7 个场景中的 6 个获得第一（总胜率 56%），在 logo 设计（71%）、线上营销活动（67%）、线下推广物料（63%）三个场景优势尤为显著；即梦在商品海报设计场景拿到第一（50%）；Roboneo 在全部场景中落后于另两家，但在 IP 形象设计场景中具有一定竞争力（38%）。

本文的核心贡献不在于产品排名本身，而在于提供一套**可被任何研究者或从业者复用的开源评测框架**，使 AI 设计工具的能力对比从"感觉驱动"走向"数据驱动"。任务集、评测工具链与完整结果数据已开源：https://github.com/SanJueLogic/ai-design-benchmark

关键词：AI 设计工具评测、Benchmark、SbS 双盲评测、企业场景、评测方法论

1. 引言

1.1 研究动机

企业数字化设计需求正在快速增长，AI 设计工具（AI Design Agents）作为辅助或替代人工设计的新一类工具，在 2024–2025 年出现了大量商业产品。然而，与 LLM 领域已建立的 MMLU、HELM、SWE-bench 等标准化评测体系不同，AI 设计工具领域至今没有公开可引用的横向评测框架。

企业采购方和设计从业者在选择工具时，主要依赖三类不可靠的信息来源： 1. **厂商自述**：宣传材料中的案例多为精选示例，不能反映真实任务成功率 2. **个人体验**：主观性强，缺乏可控变量，无法复现 3. **社区口碑**：受传播偏差影响，高曝光产品未必真正适合特定使用场景

本文尝试填补这一空白，提供一套**设计场景化、评测流程双盲化、结果聚合算法化、置信度显式化**的评测方法论，并以 Round 1 的实证数据验证其有效性。

1.2 现有评测体系的不足

AI 图像类工具的公开评测主要集中在以下几类：

评测类型	代表工作	不足
文生图通用质量	DrawBench、GenEval	仅考察单张图质量，不涉及多轮任务执行或设计场景需求
AI 代码代理	SWE-bench、HumanEval	领域不同，无法迁移
多模态理解	MMMU、MMBench	偏感知能力，不考察设计执行
设计工具商业评测	行业报告、KOL 体验	无标准任务集、无盲测保障、无置信度说明

本文与上述工作的核心差异在于：**任务集来自真实企业设计场景、评测采用双盲 SbS 排序投票、结果聚合算法公开可复现、置信度基于票数集中度显式量化。**

1.3 本文贡献

1. **场景化任务集**：覆盖 7 个企业级设计场景、115 个任务、4 种题型（模糊/明确/编辑/复合），是首个面向 AI 设计工具的公开标准化任务集
2. **双层指标体系**：客观底线（Pass/Fail）+ 主观高线（0–2 分）的两级评测标准，避免纯主观评分的稳定性问题
3. **双盲 SbS 评测制度**：评测员在不知道图片来源的情况下逐题投票，有效控制品牌偏见

4. **可复现的结果聚合算法**：四层聚合（题目→任务→场景→总榜）+ 票数集中度置信度，给出明确的"可直接引用"与"需谨慎引用"阈值
5. **Round 1 实证验证**：在 7 个场景中对 3 款公开产品完成 SbS 横评，提供完整数据集和分析

1.4 文档结构

第 2 章介绍评测目标与范围；第 3 章阐述设计任务特征与评测原则的理论基础；第 4–5 章定义指标体系与评测标准；第 6 章描述任务集设计与数据结构；第 7 章介绍评测方式与题目设计；第 8 章给出结果聚合与置信度算法；第 9 章说明实验设置与可复现性；第 10 章报告 Round 1 实验结果；第 11–13 章讨论伦理局限、未来工作与结论。附录提供术语表、完整指标定义、任务样例和结果数据表。

---

2. 评测目标与范围

2.1 评测对象

Round 1（本文）：覆盖 3 款目前市场上具有代表性的公开 AI 设计工具：

产品	产品形态	测试版本时间
Lovart	对话框 + 画布	2026–03 至 2026–04
即梦	对话框 + 无限画布	2026–03 至 2026–04
Roboneo	对话框 + 画布	2026–03 至 2026–04

> ⚠️ AI 产品迭代速度快，本文结论基于特定时间窗口内的版本，随产品更新结论可能变化。

2.2 评测场景

覆盖企业设计需求中高频出现的 7 个场景：

#	场景	任务数	评测员数
1	Logo 设计	17	5
2	IP 形象设计	16	7
3	徽章 & 奖杯设计	19	7
4	商品海报设计	16	7
5	商品图片美化	13	6

#	场景	任务数	评测员数
6	线上营销活动设计	18	6
7	线下推广物料设计	16	6
	合计	**115**	**10（各场景6–7人）**

2.3 评测任务集说明

Round 1 使用的任务集为"通用竞品评测版"，采用虚构品牌"星选"（吉祥物"萌星"）替代任何真实商业品牌，确保任务集可被任何研究者或从业者直接复用。任务集已开源，见第 6 章及附录 C。

---

3. 理论基础：设计任务特征与评测原则

> 本章内容基于对企业级设计任务的系统性分析，推导出评测框架的基础假设。

3.1 设计任务的三大核心特征

特征一：需求表达天然模糊 设计任务中，业务方往往只能描述期望的感觉或结果，而非精确的技术规格。这意味着对"任务理解"的评测不能只检验"有没有按字面要求做"，还必须检验"是否理解了意图背后的设计目标"。

特征二：输出质量兼具客观基线与主观高线 – 客观底线：是否存在畸变、错字、尺寸不符等不可上线的技术性问题 – 主观高线：视觉风格、信息传达、创意感等无唯一正确答案的评价维度

特征三：使用场景决定质量标准 线下推广物料（展架、横幅）与线上营销活动（Banner、落地页）的设计语言不同；Logo 设计与 IP 形象设计对原创性和一致性的要求不同。这意味着评测标准必须场景化，而非一套通用标准打天下。

延伸：交付可用性是设计 Agent 的核心价值锚点 区别于图像生成模型，设计 Agent 的核心价值在于"交付可直接送给客户或上线使用的成果"，而非"生成一张图片"。用户衡量的是"这张图我能不能直接用"，而非"这张图好不好看"。这一特征对评测设计的影响是：除技术质量和视觉质量外，必须设置"甲方能否直接通过"作为综合验收指标，将交付可用性显式化。

3.2 三条评测原则

由上述特征推导出三条核心原则：

原则一：双层标准 客观标准先于主观标准，任何触发客观底线的输出直接标记为不可用（Pass/Fail），不进入主观评分。主观评分仅在客观底线通过后才有意义。

原则二：场景化任务集 不使用通用任务集，为每个设计场景单独设计任务集，确保任务的典型性和场景代表性。任务集覆盖四种题型（模糊/明确/编辑/复合），全面考察工具的能力边界。

原则三：双盲 SbS 横评 在涉及竞品横向对比时，采用双盲机制（评测员不知道图片来源产品），以图片排序投票代替绝对评分，控制品牌偏见，提升对比结论的可信度。

---

4. 指标体系

4.0 从设计师工作链路推导指标

评测指标的设计出发点不是"这张图好不好看"，而是**"一个设计需求算不算真正完成了"**。如果从图像美观度出发，得到的是图像质量评测，不是设计 Agent 评测——因为设计 Agent 还要理解需求、选择策略、交付可落地的成果，不只是画一张图。

所有设计任务的工作链路是相同的：承接需求 → 执行制作 → 交付成果 → 验证效果。沿链路追问"什么情况算做好了"，可以推导出两类性质不同的判断：

链路阶段	核心问题	判断性质	对应指标层
承接 + 执行	是否正确理解需求、有无漏项、有无技术硬伤?	有明确对错，可客观判定	**客观底线层**
交付 + 验证	成果能否有效传达信息、在受众那里产生对应感受?	涉及受众感受，需主观评估	**主观质量层**

场景差异体现在每层内部的具体检查内容上，但框架在所有场景中通用——这正是本体系能跨 7 个场景一致计算综合胜率的基础。

4.1 五大评测维度

维度	类型	说明
任务理解与执行	客观	是否按要求执行了尺寸、元素、风格等指定条件
基础专业质量	客观	无畸变、无错字、图像清晰、元素完整
内容合规性	客观	品牌元素正确、无违禁内容（仅适用于品牌版任务集）
信息传达效果	主观	重点信息突出、层次清晰、内容可读
视觉体验效果	主观	风格契合、配色合理、构图美观

4.2 双层标准结构

```
客观底线（Pass/Fail）
├── 任务理解与执行
├── 基础专业质量
└── 内容合规性
    → 任意触发 → 标记为"不可用"，不进入主观评分

主观高线（各占 50%）
├── 信息传达效果（0-2 分）
└── 视觉体验效果（0-2 分）
    → 仅用于版本迭代对比，不单独决定上线与否
```

4.3 SbS 评测中的指标映射

SbS（轨道二）使用固定评测题目，每道题对应一个评测维度：

评测题目	对应维度	类型
对照任务 Prompt，哪张图的完成度最高？	任务理解与执行	客观
哪张图图形/文字最准确，没有崩坏/错别字问题？	基础专业质量	客观
哪张图最有记忆点，创意和设计感最强？	视觉体验效果	主观
哪张图最适合实际商用，放在各类品牌物料上都合适？	信息传达效果	主观
如果你是甲方，收到这几张图，你会直接通过哪张？	综合应用性	混合

---

5. 评测标准构建

5.1 客观底线标准（Pass/Fail）

以下任一条件触发，该产品对本任务的输出判定为"不可上线"：

维度	不可上线条件
任务理解与执行	关键元素缺失（要求含 Logo 但生成图中无 Logo）；尺寸规格严重偏差（要求横版但生成竖版）；未执行指定风格限制
基础专业质量	人物/动物出现明显畸变；文字出现错别字或乱码；图像存在严重伪影、模糊、裁切异常
	品牌元素使用错误（颜色、Logo 形变）；出现涉黄、涉政、侵权等违规内容

维度	不可上线条件
内容合规性	

5.2 主观高线量表（0–2 分）

分值	说明
2	表现优秀，明显优于同类需求的平均水平，无明显改进需求
1	表现达标，基本满足需求但有可优化之处
0	表现较差，低于同类平均水平，需要明显改进

5.3 SbS 评测选项规范

所有 SbS 排序题统一使用以下选项，不因场景或任务而变动：

选项	含义	是否计入胜率
A / B / C	对应产品最好	✅ 是
差不多	多款产品质量相当，无法选出最好	❌ 否
此题目与任务无关	题目描述与当前任务不对应	❌ 否

---

6. 任务集（Benchmark Dataset）

6.1 任务集框架

设计理念：一个好的设计任务集，应当覆盖"用户真实会提出什么样的需求"，而非只考察工具的技术能力上限。为此，任务集采用四种题型全覆盖的方式：

题型	说明	任务比例
模糊任务	需求开放，考验模型对设计意图的自主理解能力	约 25%
明确任务	需求具体，考验模型对精确指令的落地执行能力	约 25%
编辑型需求	在已有图上做局部修改，考验图像理解与编辑能力	约 25%
复合型需求	一个需求中隐含多个子任务，考验综合执行能力	约 25%

通用版（本文使用）：每场景 15–19 条任务，采用虚构品牌"星选"（吉祥物"萌星"），去除任何真实企业的特异性信息，可直接用于评测任意 AI 设计工具。

6.2 任务数据结构与字段定义

每条任务以 YAML/JSON 格式定义，包含以下 8 个字段：

```
task_id: "L-001"            # 唯一标识符（场景前缀 + 序号）
scene: "logo设计"       # 所属设计场景
task_type: "模糊任务"     # 四种题型之一
prompt: "生成一个古朴高级感的茶馆品牌 logo"    # 完整提示词
reference_images:           # 编辑型任务所需参考图（模糊/明确/复合型为空）
  - "images/L-001_ref.jpg"
benchmark_version: "v2.0"    # 任务集版本号
data_source: "通用竞品版"   # 版本类型
evaluation_questions:        # 适用的评测题目列表
 - "对照任务 Prompt，哪张图的完成度最高？"
 - "哪张图图形/文字最准确，没有崩坏/错别字问题？"
 - "哪张图最有记忆点，创意和设计感最强？"
 - "哪张图最适合实际商用？"
 - "如果你是甲方，你会直接通过哪张？"
```

6.3 两套任务集的设计分化

维度	通用竞品版（本文使用）	企业业务版（不公开）
品牌元素	虚构品牌"星选"	真实企业品牌（已脱敏）
场景覆盖	7 个通用商业场景	覆盖企业特定业务场景
任务总数	115 条	额外包含企业特异性任务
开放状态	✅ 完全公开	❌ 仅供内部使用

6.4 任务集访问与引用协议

任务集已托管于 GitHub，采用 **CC BY 4.0** 协议开放使用：

```
ai-design-benchmark/
└── dataset/
    └── v1.0/
        ├── tasks.json              # 结构化任务集（全部 115 条）
        ├── scenes/                 # 按场景分组的 Markdown 格式任务书
        │   ├── logo-design/
        │   ├── ip-design/
        │   ├── badge-trophy/
```

```
        │   ├── product-poster/
        │   ├── product-image/
        │   ├── online-marketing/
        │   └── offline-material/
        └── reference-images/      # 编辑型任务参考图
```

引用格式（BibTeX）：

```
@misc{liu2026aidesignbenchmark,
  title     = {AI Design Agent Benchmark: A Scenario-Based Evaluation Framework},
  author    = {Liu, Xuedong},
  year      = {2026},
  url       = {https://github.com/SanJueLogic/ai-design-benchmark},
  note      = {Round 1, v1.0}
}
```

---

7. 评测方式与题目设计

7.0 为什么选择 SbS

本轮评测目标是竞品横向对比，需要直接产出"谁比谁好"的结论。对主流评测方式逐一对照，得出选择 SbS 的理由：

评测方式	核心过程	优劣分析	是否采用
SbS 对比评测	把多款产品并排，让评测员选最优	直接产出竞品排名；判断"哪个更好"比"该打几分"认知门槛低，评测员执行更稳定	✅ 采用
单图绝对打分	对单张结果独立打 1–5 分	不直接产出竞品排名，但适合版本迭代时的纵向对比	保留用于单产品版本验收
ELO 排名制	像赛事积分动态更新排名	需要极大样本量，6–7 名评测员不够	❌ 不适用
LLM–as–Judge	让大模型自动打分	对构图、调性等主观判断的准确率不足	❌ 不适用
自动化指标	算法计算图像技术质量	只测图像层面，不测设计意图理解	❌ 不用于主评测

7.1 双轨评测制度

轨道	适用场景	产品数量	评测方式
轨道一（单图打分）	单一产品能力纵向评估	1 款	逐题打分（Pass/Fail + 0–2 分）
轨道二（SbS 排序）	多产品横向对比（本文使用）	3+ 款	同时查看多款产品结果，逐题选最好

本文 Round 1 仅使用轨道二，聚焦 3 款产品的横向对比。

7.2 SbS 评测执行流程

```
准备阶段（管理员）
├── 对 3 款产品跑全部 115 个任务，保存生成结果图
├── 将同一任务的 3 张结果图随机打乱顺序，标记为 A/B/C
└── 确保评测员无法通过产品界面特征识别来源（截图脱水印）

评测阶段（评测员）
├── 评测员同时看同一任务的 3 张结果图（A/B/C）
├── 逐题选出表现最好的一张（或选"差不多" / "与任务无关"）
└── 全程不知道 A/B/C 对应哪个产品（双盲）

汇总阶段（管理员）
├── 揭盲：将 A/B/C 映射回真实产品名
└── 运行聚合脚本生成胜率数据
```

7.3 评测题目设计原则与流程

题目设计的核心目标是：让评测员每次选择都有据可依，而不是凭感觉选。按四步完成：

步骤一：从评测标准派生题目。 各场景已有两级评测标准（客观底线 + 主观高线，见第 5 章），题目就是把这套标准转成评测员能直接看图作答的判断题。

步骤二：控制题目数量。 固定每场景 5 道题：4 道按维度出的核心题（任务理解、基础质量、信息传达、视觉体验）+ 1 道"甲方是否通过"综合题。题目过多会造成评测员疲劳，质量变差。

步骤三：按场景调整措辞。 同一维度在不同场景问法不同（Logo 场景问"字体是否准确、无崩坏"，IP 形象场景问"角色比例是否正确、持握是否自然"），但对应维度相同，结论仍可横向对比。

步骤四：去掉专业术语。 "对比度、层次感、视觉留白"等术语全部改为"没有错字"、"没有畸形元素"等直接可观察的描述，非设计背景的评测员也能直接作答。

四条底线原则： 1. **直接可观察**：只看图即可回答，无需想象使用效果 2. **小学生可读**：语言简洁直白，无行业术语 3. **维度全覆盖**：客观维度（任务完成度、专业质量）+ 主观维度（创意感、商用适配）都有对应题目 4. **全场景通用**：同一场景下的所有任务使用相同的一套题目，不单独出题

7.4 评测员招募与盲测协议

本次 Round 1 评测员构成：

职能背景	代号	人数	参与场景	设计工作年限
设计	E01–E05	5	全部 7 个场景	3–8 年
研发	E06–E09	4	全部 7 个场景	4–10 年（含设计工具使用经验）
算法	E10	1	4 个场景	3 年（参考性数据）

评测员资质说明：设计职能（E01–E05）均具备品牌视觉、营销物料或 IP 设计方向的实际项目经验，能独立判断"是否可直接交付给客户"；研发职能（E06–E09）均有 AI 产品相关工作背景，具备评估生成图像质量和任务执行准确性的能力；算法职能（E10）主要提供技术维度视角参考，数量不足不计入主要结论。

> 完整评测员协议（含知情同意书模板）见 GitHub 库 `docs/evaluator-protocol.md`。

盲测保障措施： – 产品结果图统一去除水印，仅标注随机字母（A/B/C） – 评测员在评测期间不交流，独立完成 – 管理员在所有评测员完成后才揭盲 – 每轮评测结束后对评测员进行简短的结果认知调查，识别是否存在系统性品牌偏见

---

8. 结果聚合与置信度算法

8.1 四层聚合架构

```
投票层（原始数据）
    ↓ 逐题统计各产品被选次数
题目层（每任务 × 每题目 → 胜者）        ← 第 1 层：回答"谁赢了这道题"
    ↓ 统计每产品赢得的题目数
任务层（每场景 × 每任务 → 胜者）        ← 第 2 层：回答"谁赢了这个任务"
    ↓ 统计每产品赢得的任务数
场景层（每场景 → 胜率）                ← 第 3 层：回答"谁赢了这个场景"
    ↓ 按任务数加权
```

```
总榜层（综合胜率）
  ↑ 旁支
维度层（第 1 层数据按维度重新分组）    ← 第 4 层：回答"谁赢在哪个维度"
```

第 4 层维度级统计是对第 1 层数据的重新切割：把同一维度（如"任务理解与执行"）在所有场景中的投票汇总，产出各产品在该维度的累计得票率。第 1–3 层回答"谁赢了"，第 4 层回答"赢在哪里"——最终可定位到"Lovart 在 Logo 场景任务执行维度领先、视觉体验维度接近"，而非笼统的"Lovart 总分高"。

8.2 计分伪代码

```
SKIP_OPTIONS = {"差不多","此题目与任务无关"}
PRODUCTS = ["Lovart", "即梦","Roboneo"]

def compute_win_rate(raw_votes: dict, scene_name: str) -> dict:
  """
    raw_votes: {场景:{评测员:{role, questions, scores}}}
  返回:{产品: 胜率}
  """
  # 1. 题目层聚合：统计每题每产品的票数
    task_q_votes = defaultdict(lambda: defaultdict(Counter))
    task_names = []

    for evaluator, ev_data in raw_votes[scene_name].items():
        task_names = ev_data["questions"]
        for q_name, votes in ev_data["scores"].items():
            for task_idx, vote in enumerate(votes):
                if vote in SKIP_OPTIONS:
                    continue
                product = OPTION_TO_PRODUCT[vote]
                task_q_votes[task_idx][q_name][product] += 1

  # 2. 任务层聚合：每任务 → 赢得题目数最多的产品获胜（允许并列）
    task_winners = []
    for task_idx in range(len(task_names)):
        q_win_counts = Counter()
        for q_name, prod_votes in task_q_votes[task_idx].items():
            if not prod_votes:
                continue
            max_v = max(prod_votes.values())
```

```
            for p, v in prod_votes.items():
                if v == max_v:
                    q_win_counts[p] += 1
        if not q_win_counts:
            continue
        max_wins = max(q_win_counts.values())
        task_winners.append({p for p, c in q_win_counts.items() if c == max_wins})

    # 3. 场景层：赢得任务数 / 总任务数 = 场景胜率
    total_tasks = len(task_winners)
    product_wins = Counter()
    for winners in task_winners:
        for p in winners:
            product_wins[p] += 1

    return {p: product_wins.get(p, 0) / total_tasks for p in PRODUCTS}
```

8.3 置信度判定机制

本框架采用**票数集中度法**作为置信度指标，不使用传统的 Kappa 一致性系数。原因：本评测刻意纳入多职能评测员，不同职能对设计质量的评判标准本就有合理分歧，低 Kappa 反映的是视角多样性，不代表结论不可信。

第一步：判断整体集中度

把每道题的投票画成柱状图（横轴 = 三款产品，纵轴 = 得票数）：

形态	含义	处理方式
某款产品票数明显高出其他两款	不同职能的评测员都偏向同一款 → 共识强	结论可信，直接引用
三款产品票数大致相当	投票接近随机分布 → 进入第二步职能拆分	不直接引用

第二步：整体平直时按职能拆分

若整体结果呈平直分布，不代表结论无意义——可能只是不同职能各自选了不同产品（设计偏好 A，研发偏好 B）。此时按职能分组重新统计：

- **各职能内部有一致倾向但方向不同** → 职能分歧：本身是有价值的信号，说明不同视角对产品能力有不同判断，引用时需注明职能背景
- **各职能内部也呈平直分布** → 真正的低置信度：优先检查是题目设计缺陷，还是竞品结果本身极为接近

置信度阈值（3 选 1 随机基准为 33%）：

置信度等级	判定条件（第一名与第二名胜率差）	引用建议
✅ 高（可直接引用）	差距 ≥ 20%	结论稳定，可直接引用
⚠️ 中（谨慎引用）	差距 10–20%	需说明样本量，扩大评测员后验证
❌ 低（不建议引用）	差距 < 10%	在当前评测员规模下统计意义有限

> Round 1 通过此机制识别出 2 道设计缺陷题目（见 §10.5），将在 Round 2 中替换。

---

9. 实验设置与可复现性

9.1 竞品选择与版本说明

产品	选择理由	评测时版本状态
Lovart	2024–2025 年 AI 设计领域融资最多、用户基数最大的代表性产品	2026–03 至 2026–04 线上版本
即梦	国内头部图像生成平台延伸的 AI 设计工具，具有较强的图像质量基础	2026–03 至 2026–04 线上版本
Roboneo	独立 AI 设计 Agent 中的代表性产品	2026–03 至 2026–04 线上版本

> ⚠️ 所有产品均使用普通用户账号，不使用任何内测版本或 API 调用，确保结果反映真实用户体验。

9.2 数据采集流程

自动化工具辅助：使用基于 Chrome DevTools Protocol 的浏览器自动化脚本，完成提示词输入、结果图下载的批量操作。脚本代码已包含在 GitHub 库 `tools/data-collection/` 目录下。

文件命名规范：

```
[场景前缀]-[序号]_result.jpg      # 生成结果图
[场景前缀]-[序号]_screenshot.png  # 截图（记录生成过程）
```

失败处理：若任务在 180 秒内未完成生成，自动发送"继续重试"指令；若再次失败则标注为"生成失败"，不纳入评测数据。

生成耗时观察（Round 1 部分记录）：

> ⚠️ 受自动化脚本早期版本限制，Round 1 耗时数据仅部分场景完整记录。以下数据供参考，Round 2 将全面记录。

产品	使用模型	耗时区间（秒）	备注
Lovart	图片生成工具（快速模式）	85–264	多数任务走此模式
Lovart	Nano Banana Pro（精细模式）	505–1643	含多次超时重试任务
即梦	图片 5.0 Lite	170–500	数据来自补录重测
即梦	图片编辑模式	200–540	编辑型任务
Roboneo	—	—	Round 1 未系统记录

耗时差距主要由模型版本选择和服务器负载决定，作为工具选型参考指标。Round 2 将纳入"P90 耗时"作为正式评测维度之一。

9.3 评测执行手册

完整的评测执行步骤记录于 GitHub 库 `docs/how-to-run-a-round.md`，包含： – 评测准备清单（共 8 步） – 揭盲前产品随机化方法 – 评测员操作指引 – 数据回收与核查流程

9.4 工程复现清单

任何人希望复现本轮评测，需完成以下步骤：

1. `git clone https://github.com/SanJueLogic/ai-design-benchmark`，安装依赖（Python 3.10+，openpyxl，pandas）
2. 在 3 款产品上分别运行 `dataset/v1.0/tasks.json` 中的全部 115 个任务
3. 将结果图按命名规范存入 `results/your-round/raw/[产品名]/`
4. 编写或修改 `tools/sbs-template/` 中的投票界面，招募评测员完成盲测
5. 将评测结果按 `results/round-1/raw-votes.json` 格式整理
6. 运行 `python tools/scoring.py --input results/your-round/` 生成聚合结果
7. 运行 `python tools/confidence.py` 生成置信度报告
8. 对比 `results/round-1/aggregated.csv`（本文基准数据）

9.5 数据污染防护（Contamination Protocol）

数据污染（Contamination）是指被评测产品的训练数据中已包含评测任务相关内容，导致结论虚高。本框架采用以下措施防护：

虚构品牌隔离：全部 115 条任务均采用虚构品牌"星选"（吉祥物"萌星"），该品牌由作者于 2025 年底原创，未在任何公开平台发布或参与商业运营。三款被评测产品的训练数据中不存在"星选"品牌相关的设计案例，有效防止了品牌先验知识对生成结果的干扰。

Prompt 原创性：所有任务提示词由评测框架设计者原创撰写，未基于公开设计题库或已有评测集改编。全量任务集与版本哈希已锁定至 GitHub `dataset/v1.0/` 目录。

评测对象无关性：本框架的核心判断是"哪款产品在当前任务中执行更准确"，由评测员直接对生成结果投票——即使竞品曾见过相似描述，也不会改变"执行结果孰优孰劣"这一人工判断。

时间窗口冻结：评测数据采集于 2026 年 3–4 月，任务集于采集完成后版本锁定，不再追加任务。

---

10. 实验结果（Round 1）

10.1 总榜：3 款产品综合表现

排名	产品	赢得任务数	总胜率	第一场景数	综合评价
🥇 1	Lovart	64 / 115	**56%**（95% CI: 47%–64%）	6	在 logo、线上营销、线下推广等执行类场景中具有全面优势
🥈 2	即梦	31 / 115	**27%**（95% CI: 19%–35%）	1	商品海报场景的视觉表现突出，其余场景偏弱
🥉 3	Roboneo	22 / 115	**19%**（95% CI: 12%–27%）	0	全场景落后于另两家，在 IP 形象设计中相对有竞争力

> 注：允许并列多赢，各产品任务数之和可能超过 115。随机基准为 33%（3 选 1）；置信区间基于 10,000 次 task-resample Bootstrap（seed=42）。Lovart 56% 为本轮评测三款产品中的最优表现（SOTA）；理论上限为 100%（单产品赢得全部任务）。

10.2 场景级详细结果

场景	🥇 Lovart	🥈 即梦	🥉 Roboneo	总任务数	可信度
Logo 设计	**71%**（12任务）	18%（3任务）	18%（3任务）	17	✅ 高（差距 53%）
				18	

场景	🥇 Lovart	🥈 即梦	🥉 Roboneo	总任务数	可信度
线上营销活动	**67%**（12任务）	17%（3任务）	22%（4任务）		✅ 高（差距45%）
线下推广物料	**63%**（10任务）	19%（3任务）	19%（3任务）	16	✅ 高（差距44%）
徽章奖杯设计	**63%**（12任务）	32%（6任务）	5%（1任务）	19	✅ 高（差距31%）
商品图片美化	**46%**（6任务）	38%（5任务）	15%（2任务）	13	❌ 低（差距8%）
商品海报设计	31%（5任务）	**50%**（8任务）	19%（3任务）	16	⚠️ 中（差距19%）
IP 形象设计	**44%**（7任务）	19%（3任务）	38%（6任务）	16	❌ 低（差距6%）

10.3 任务类型视角

任务类型	🥇 第一名	胜率	🥈 第二名	胜率	核心洞察
模糊任务	Lovart	约52%	即梦	约28%	Lovart 在自主填补需求空白时风格更受认可
明确任务	Lovart	约61%	即梦	约24%	Lovart 对精确指令的落地执行最稳定
编辑型需求	Lovart	约58%	即梦	约27%	Lovart 在图像局部修改上具有优势
复合型需求	Lovart	约45%	即梦	约32%	所有类型中竞争最接近，但 Lovart 仍领先

> 以上胜率为近似估算（各类型任务总量较小，四舍五入误差较大）。详细逐任务类型分类统计见 GitHub 库 `results/round-1/task-type-breakdown.csv`（阶段二发布时补充）。

10.4 职能分歧与可信度分析

依据 §8.3 票数集中度机制，各场景第一、第二名胜率差与置信度汇总如下：

场景	第一名	胜率	第二名	胜率	差距	置信度
Logo 设计	Lovart	71%	即梦/Roboneo	18%	53%	✅ 高
线上营销活动	Lovart	67%	Roboneo	22%	45%	✅ 高
线下推广物料	Lovart	63%	即梦/Roboneo	19%	44%	✅ 高
徽章奖杯设计	Lovart	63%	即梦	32%	31%	✅ 高
商品海报设计	即梦	50%	Lovart	31%	19%	⚠️ 中
商品图片美化	Lovart	46%	即梦	38%	8%	❌ 低
IP 形象设计	Lovart	44%	Roboneo	38%	6%	❌ 低

职能分歧说明：

- **商品海报设计（⚠️ 中）**：设计职能更偏向即梦的视觉风格，研发职能整体更认可 Lovart 执行稳定性；职能偏好分歧缩小了整体差距，引用时建议注明评测员职能构成。
- **IP 形象设计（❌ 低）**：三款产品得票差距极小（6%），各职能内部意见也较分散；建议将评测员规模扩大至 15 人以上后再得出结论。
- **商品图片美化（❌ 低）**：差距偏小源于竞品本身能力接近，并非职能意见分散所致；当前样本规模下不建议引用具体排名。
- **置信度高的 4 个场景**（Logo、线上营销、线下推广、徽章奖杯）：设计与研发职能倾向大体一致，共识较强，结论可直接引用。

跨职能分歧率汇总（设计职能多数 vs 研发职能多数选择不同产品的任务比例）：

场景	跨职能分歧率	主要分歧方向
商品海报设计	~53%	设计倾向即梦视觉风格，研发倾向 Lovart 执行稳定性
IP 形象设计	~50%	三家产品均接近，各职能内部意见散乱
Logo 设计	~41%	设计倾向即梦/Roboneo 视觉创意，研发倾向 Lovart 执行精度
商品图片美化	~31%	分歧主要源于竞品能力接近，而非职能偏好差异
线上营销活动	~22%	两职能大体一致，Lovart 整体认可度高
	~19%	两职能高度一致，Lovart 大幅领先

场景	跨职能分歧率	主要分歧方向
线下推广物料		
徽章奖杯设计	~18%	两职能高度一致，Lovart 大幅领先

> 分歧率为近似估算，详细逐任务分歧数据见 GitHub 库 `results/round-1/evaluator-divergence.csv`（阶段二发布时补充）。分歧率与置信度负相关：分歧率 >40% 的场景结论需谨慎引用。

10.5 题目质量诊断

Round 1 中发现 2 道题目存在设计缺陷，已在结果分析中剔除或标注，将在 Round 2 中替换：

题目	场景	缺陷描述
"哪张图最能激发欲望，让你想立刻下单？"	线上营销活动	题目包含"立刻下单"等商业意图词汇，与设计质量评测目标不完全一致，评测员理解有歧义
"如果是你，哪个奖杯/徽章最想珍藏？"	徽章奖杯设计	"珍藏"倾向考察个人情感偏好而非设计质量，导致该题与其他题目分歧较大

10.6 关键发现与归因

发现 1：Lovart 在明确需求场景全面领先

Logo 设计（71%）、线上营销活动（67%）、线下推广物料（63%）三个场景的共同特点是：任务有明确的规格要求或风格指向。Lovart 在精确执行指定规格方面的稳定性显著高于竞品，这与其在设计专业性方面的投入相关。

发现 2：即梦在视觉驱动场景有局部竞争力

即梦在商品海报（50%）场景中拿到第一，该场景的核心判断标准是"视觉冲击力和信息传达"，即梦的图像生成底层在视觉美观度上具有优势。但在需要精确执行设计规格的场景中，即梦的优势不能延续。

发现 3：Roboneo 在 IP 形象设计中相对有竞争力

Roboneo 在 IP 形象设计获得 38%，是三家横评中与第一名（Lovart 44%）差距最小的场景。但该场景整体置信度偏低（3 家差距 < 10%），需扩大评测员规模后再下定论。

10.7 典型失败模式分析

本节从各产品表现偏弱的场景中，抽取 Round 1 中评测员共识度较高的典型失败案例，作为后续产品改进的参考信号。案例均来自有文字备注的评测记录，结论仅代表本轮评测时间窗口内的版本表现。

Lovart 典型失败模式

模式 L-1：复合型任务子需求遗漏

在一个 prompt 同时包含多个独立子任务时（如"设计一张海报，要求包含活动标题、时间地点、二维码，并搭配促销氛围"），Lovart 偶尔会完成大部分子需求，但遗漏其中 1-2 个元素（如缺少二维码位置预留）。这一问题在线上营销活动场景中出现频次最高。评测员在"任务理解与执行"维度给出的低分主要集中于此类案例。

模式 L-2：IP 角色一致性漂移

IP 形象设计场景中的编辑型任务（如"给萌星换节日服装，但保持脸部特征不变"），Lovart 在保持角色面部特征一致性方面表现不稳定，部分生成结果出现鼻型、眼距等面部特征的细微变形，导致"是同一个角色"的可辨识度下降。这是 Lovart 在 IP 场景置信度偏低的主要原因。

模式 L-3：模糊任务风格偏国际化

在需求较为模糊（如"设计一款年轻时尚风格的Logo"）、允许自主发挥的任务中，Lovart 的默认输出风格倾向偏向国际化平面设计审美（大留白、线条感强），与部分中国市场评测员对"年轻时尚"的预期存在偏差，导致主观维度分歧增大。

即梦 典型失败模式

模式 J-1：明确规格遵从率偏低

在有明确字体风格、色彩要求或元素数量约束的任务中（如"用红金配色，主字体需为衬线体"），即梦的遵从率整体低于 Lovart。主要表现为：颜色系统执行不准确（红金 → 偏橙红）、字体类型与要求不符（无衬线体 → 衬线体混用）。这是即梦在 Logo 设计和线下推广物料场景表现偏弱的核心原因。

模式 J-2：线下物料尺寸比例失真

在展架（60cm×160cm）、横幅（300cm×80cm）等线下推广物料类任务中，即梦对竖向/横向长比例的版式处理不稳定，生成结果有时出现内容压缩变形或大面积留白，影响"可直接用于印刷"的可用性评价。

模式 J-3：文字渲染偶发错误

商品海报和 Logo 设计场景中，即梦在渲染中文文字时偶发字符变形或错别字（如"活动"被渲染为"活劫"），在客观评测维度（基础专业质量）直接失分。该问题在 Round 1 中有 3–4 次记录，非普遍性问题，但在关键题目中影响较大。

Roboneo 典型失败模式

模式 R–1：任务需求相关性偏低

Roboneo 在多数场景中存在"生成了一张图，但与 prompt 核心需求关联度不高"的系统性问题。典型表现：任务要求"设计一张含有星选品牌元素的活动海报"，Roboneo 生成的结果缺少品牌名称文字，整体更接近通用风格图而非定制化设计。

模式 R–2：编辑型任务理解失准

在需要上传参考图并基于参考图进行修改的编辑型任务中，Roboneo 有时无法准确理解"保留参考图中的X，修改Y"的修改意图，生成结果与参考图视觉差距较大，表现为"重新生成了一张新图"而非"在原图基础上修改"。

模式 R–3：复合任务仅完成首个子需求

在 prompt 含有多个子任务的复合型需求中，Roboneo 倾向于只完成第一个子需求，后续子任务的落地率明显低于其他产品。这与其在复合型任务（约 32% 胜率）中落后于 Lovart（约 45%）的整体数据一致。

> **图片参考**：Round 1 典型失败案例原图存档于 GitHub 仓库 `results/round-1/failure-cases/`（阶段二发布时补充）。

---

11. 伦理与局限

11.1 评测员知情与数据处理

- 本次 Round 1 评测员均为自愿参与，了解评测目的和数据用途
- 评测员匿名代码（E01–E10 等）在数据文件中保留，不对外公开真实姓名
- 对外发布的分析报告中仅呈现聚合数据，不呈现单一评测员的投票记录

11.2 方法局限

局限	具体说明	影响范围
场景覆盖有限	仅覆盖 7 个场景，文化 T 恤、商品包装、营销动效等场景未涵盖	结论不能代表 AI 设计工具的全部能力
评测员规模较小	每场景 6–7 人，当前结论在票数集中度偏低（差距 <10%）的场景中统计意义有限	商品海报、IP 形象设计等场景结论需扩大评测员后验证

局限	具体说明	影响范围
快照性质	AI 产品迭代速度快，当前数据代表特定时间窗口	3 个月后结论可能已发生变化
评测员职能构成	以设计和研发职能为主，缺乏目标用户（企业业务方）视角	审美类题目存在职能偏差

11.3 数据时效性声明

本文 Round 1 数据采集时间为 2026 年 3–4 月。AI 设计工具产品更新频繁，本文结论仅代表数据采集时间窗口内的版本表现，不代表各产品的长期综合实力。引用时请注明数据时间。

---

12. 未来工作

Round 2 优化方向

1. **替换 2 道缺陷题目**（线上营销活动"激发欲望"题、徽章奖杯"最想珍藏"题）
2. **扩大评测员规模**：每场景从 6–7 人扩大至 15–20 人，增加业务方职能
3. **补充 3 个缺失场景**：文化 T 恤、商家 Logo（小商家场景）、营销动效
4. **新增多轮对话评测**：当前仅评测单轮提示词，Round 2 引入"2 轮达标率"指标

长期方向

- **开放众包评测**：依托官网 SbS 投票系统，扩大评测员样本至数千人级别
- **API 对接**：为各产品提供标准化 API 任务提交接口，减少手动执行成本
- **多语言任务集**：当前任务集为中文，后续推出英文版以覆盖国际评测场景

社区生态建设（参照 BIG-Bench 模式）

本框架长期目标之一是建立类似 BIG-Bench 的社区贡献机制，让研究者和从业者能够低门槛地提交新任务、新场景：

- **task.json 标准 Schema**：所有任务以结构化 JSON 描述（场景、题型、提示词、参考图路径、难度标签），GitHub 库提供标准模板
- **PR 贡献模板**：外部贡献者通过 Pull Request 提交新任务，维护者按 `任务原创性 / 无品牌特异性 / 四题型覆盖` 三条标准审核
- **Verified 子集**：经 Round 2 扩大评测员（≥15 人）复核验证的任务，标记为高置信度子集（`verified: true`），对应论文中的 ✅ 标记场景
- **对抗性子集（Adversarial Subset）**：专门设计用于暴露产品弱点的"硬样本"（如极端比例要求、多级嵌套子任务、跨语言 IP 风格迁移），在 Round 2 中作为专项任务集发布

评测维度扩展

扩展方向	说明	优先级
生成耗时（完整记录）	Round 1 部分缺失，Round 2 全任务强制记录	P0
成本估算	各产品每张图生成成本（需各产品定价数据，精度存疑）	P2
Circular Evaluation	同一题目多种问法以去除顺序偏差（SbS 盲测已天然去除此偏差，优先级低）	P2
国际化任务集	英文任务子集，arXiv 英文版发布时一并上线	P1

---

13. 结论

本文提出了一套面向企业级 AI 设计工具的系统性评测框架，并以 Round 1 的实证结果验证其有效性。核心贡献包括：场景化任务集（115 任务 × 7 场景）、双层评测指标体系、双盲 SbS 投票机制、四层聚合算法与置信度量化方法。

Round 1 的主要发现：在 3 款公开 AI 设计工具的横向对比中，Lovart 综合表现最强（总胜率 56%，6 个场景第一），在需要精确执行设计规格的场景中优势尤为显著；即梦在视觉驱动类场景中具有局部竞争力；Roboneo 与头部产品存在明显差距。

上述结论基于特定时间窗口的评测数据，样本规模有限，建议在扩大评测员规模和补充场景后进一步验证。本框架已完全开源，欢迎研究者和从业者复用、扩展。

附录 A. 术语表

术语	定义
SbS（Side-by-Side）	同时展示多款产品对同一任务的输出，由评测员选出最好的一款
双盲	评测员不知道图片来源产品（单盲），管理员在揭盲前不知道哪个产品占优（双盲的另一层）
票数集中度	第一名产品与第二名产品的胜率差值，用于量化评测结论的可信度
Kappa（κ）	Fleiss' Kappa，衡量多评测员之间选择一致性的统计量；本框架以"票数集中度"替代 Kappa（见 §8.3 理由说明）
任务胜率	某产品在某场景中赢得的任务数 ÷ 该场景总任务数

术语	定义
总胜率	某产品在所有场景中赢得的任务数 ÷ 所有场景总任务数
四种题型	模糊任务（需求开放）/ 明确任务（需求具体）/ 编辑型需求（基于参考图修改）/ 复合型需求（含多个子任务）
客观底线标准	Pass/Fail 二元判定，触发则该输出不可上线
主观高线标准	0–2 分量表，用于在客观底线通过后进一步区分质量

附录 B. 完整指标定义

B.1 Round 1 已实施的 8 项核心指标

指标	衡量什么	评测方式	计算说明
任务理解底线通过率	是否正确理解并按要求执行了任务（元素、尺寸、风格）	评测员题目投票（Q1）	该题获得最多选择的产品视为通过；未通过表示评测员认为任务执行存在明显偏差
基础质量底线通过率	是否存在错字、畸变、模糊等技术硬伤	评测员题目投票（Q2）	同上
视觉体验效果得分	视觉呈现能否营造恰当氛围，风格、配色、构图是否合适	评测员题目投票（Q3）	题目层胜率，参与维度级统计
信息传达效果得分	核心信息能否清晰高效传递，信息层级是否分明	评测员题目投票（Q4）	同上
综合应用性（甲方通过率）	如果你是甲方，收到这几张图，你会直接通过哪张	评测员题目投票（Q5）	同上
任务胜率	某产品在某场景中赢得的任务数 ÷ 该场景总任务数	四层聚合第 2–3 层	赢得题目数最多 → 赢得该任务；赢得任务数最多 → 赢得该场景
场景胜率	某产品在某场景中的综合表现	四层聚合第 3 层输出	同任务胜率定义
总胜率	所有场景加总的综合表现	总榜层	所有场景赢得任务数 ÷ 所有场景总任务数

B.2 置信度元指标

元指标	说明
票数集中度	第一名产品与第二名产品的胜率差值，用于量化结论的统计可信度
职能分歧度	设计职能与研发职能在同一题目的选择分歧程度，用于识别"职能合理分歧"与"低置信度"

B.3 V2 规划新增指标（Round 2 后引入）

指标	衡量什么	引入原因
2 轮达标率	给一次修改意见后，第二轮能否达标	弥补一次可用率的盲区——有些产品第一次不好但会改，这是重要能力
修改响应准确率	给具体修改指令后，能否准确响应（改了什么、没改什么、改错了什么）	细粒度定位哪类修改场景的理解能力较弱
底线稳定率@3	相同任务重复 3 次，能否稳定通过客观底线	解决"偶尔能做到"和"稳定能做到"之间的差距

附录 C. 7 场景任务集样例（每场景每题型 1 条，共 28 条）

> 完整任务集见 GitHub 库 `dataset/v1.0/tasks.json`

Logo 设计

题型	提示词
模糊任务	生成一个古朴高级感的茶馆品牌 logo
明确任务	设计一个运动感的服饰行业图形 logo，要求：使用蓝色系，主图形为抽象奔跑人形，需同时提供横版和方形两个版本
编辑型需求	[参考图：star-select-logo.jpg] 请在保持现有星选 logo 整体风格不变的前提下，将字体替换为更现代的无衬线字体
复合型需求	为"萌星咖啡"设计一套品牌视觉：主 logo + 横版应用版 + 单色线稿版，要求有温暖感和手工质感

IP 形象设计

题型	提示词
模糊任务	设计一个可爱的品牌吉祥物，用于儿童教育类产品
明确任务	以"萌星"（一只圆圆的橙色星形小怪兽，有大眼睛和短手短脚）为基础，设计一个"工作认真"的表情动作版本
编辑型需求	[参考图：mengxing-base.jpg] 请保持萌星整体形象不变，为它添加一顶圣诞红帽，并调整表情为开心状
复合型需求	为萌星设计三种情绪版本（开心/委屈/加油中），要求三种版本保持角色高度一致，可直接用于表情包

徽章 & 奖杯设计

题型	提示词
模糊任务	设计一枚代表"年度销售冠军"的奖章
明确任务	设计一枚六边形的电竞赛事徽章，主色调为深蓝+金色，中心图案为游戏手柄，外圈文字"星选电竞联赛 2026"，要求适合印刷在胸章上
编辑型需求	[参考图：badge-draft.jpg] 在现有徽章基础上，将外圈文字替换为"2026年度明星员工"，并在底部加上五角星装饰
复合型需求	为一个读书活动设计三级奖励体系：铜牌（读完5本）/ 银牌（读完15本）/ 金牌（读完30本），要求三个等级在风格上统一，视觉上有明显层次差异

商品海报设计

题型	提示词
模糊任务	为一款有机燕麦奶设计一张电商主图
明确任务	为"星选有机燕麦奶"设计一张 800×800 的电商主图：产品居中，背景为奶白色渐变，左上角放置"有机认证"标章，右下角放品牌 logo，整体风格清新健康
编辑型需求	[参考图：oat-milk-poster.jpg] 在现有海报基础上，将背景色改为大地色系，并在右上角增加"买二送一"角标
复合型需求	为"星选燕麦系列"设计三款产品的主图套组：原味/巧克力/草莓三款，要求视觉风格统一，每款突出各自口味特色，可作为店铺系列商品使用

商品图片美化

题型	提示词
模糊任务	对这张产品图进行美化，使其更适合电商展示
明确任务	[参考图：mug-original.jpg] 对这张马克杯图片进行以下调整：移除背景换成纯白色，增强杯体质感和光泽，保持产品比例不变
编辑型需求	[参考图：bag-product.jpg] 为这款手提袋增加使用场景：将其置于一个咖啡馆的桌面上，配上笔记本和咖啡杯，整体风格轻奢日系
复合型需求	[参考图：earphones-original.jpg] 对这张耳机产品图进行综合美化：换成渐变深色背景、增加光晕效果、在右上角叠加"Hi-Fi"文字标识、整体色调偏向科技冷色系

线上营销活动设计

题型	提示词
模糊任务	为星选平台的双十一活动设计一张 Banner
明确任务	为"星选 618 大促"设计一张 PC 端首页 Banner（尺寸 1920×400），主视觉使用红金配色，主标题"618 年中狂欢"，副标题"全场最低价"，右侧放 CTA 按钮"立即抢购"
编辑型需求	[参考图：banner-draft.jpg] 在现有 Banner 基础上，将活动时间从"6月1日-6月18日"改为"5月31日-6月18日"，并在左下角加上"提前开抢"小标
复合型需求	为"星选新春活动"设计一套 3 件套营销物料：PC 端 Banner（1920×400）+ 手机端 Banner（750×300）+ 方形朋友圈图（1080×1080），视觉风格统一，主题突出"新春好物低价抢"

线下推广物料设计

题型	提示词
模糊任务	为星选品牌设计一张户外广告牌
明确任务	为"星选加盟招募"设计一张 KT 板（600×900mm），内容：主标题"加入星选，共享红利"、3个核心卖点（品牌赋能/选品优先/流量扶持）、联系电话及二维码，整体风格商务大气

题型	提示词
编辑型需求	[参考图：rollup-banner.jpg] 在现有易拉宝基础上，将二维码替换为新版图，并在底部增加"扫码了解更多"提示文字
复合型需求	为星选线下展会设计一套展位物料：主背景板（3m×2.5m）+ 侧立牌（600×1800mm）+ 桌卡（200×70mm），三件套视觉风格统一，体现专业感和品牌调性

附录 D. 评测题目与评测维度映射

评测题目	对应维度	类型	适用场景
对照任务 Prompt，哪张图的完成度最高?	任务理解与执行	客观	全场景
哪张图图形/文字最准确，没有崩坏/错别字问题?	基础专业质量	客观	全场景
哪张图最有记忆点，创意和设计感最强?	视觉体验效果	主观	全场景
哪张图最适合实际商用?	信息传达效果	主观	全场景
如果你是甲方，你会直接通过哪张，不要求返工?	综合应用性	混合	全场景

附录 E. 完整结果数据表

> 完整数据见 GitHub 库 `results/round-1/aggregated.csv`。以下为关键数据摘录。

E.1 各场景 × 产品胜率（Round 1，3 家横评）

场景	Lovart	即梦	Roboneo	总任务数	第一名	置信度
Logo 设计	**71%**	18%	18%	17	Lovart	✅
IP 形象设计	**44%**	19%	38%	16	Lovart	❌
徽章奖杯设计	**63%**	32%	5%	19	Lovart	✅
商品海报设计	31%	**50%**	19%	16	即梦	⚠️
商品图片美化	**46%**	38%	15%	13	Lovart	❌
线上营销活动	**67%**	17%	22%	18	Lovart	✅
线下推广物料	**63%**	19%	19%	16	Lovart	✅

场景	Lovart	即梦	Roboneo	总任务数	第一名	置信度
总计	**56%**	**27%**	**19%**	**115**	**Lovart**	**—**

E.2 各场景赢得任务数明细

场景	Lovart 赢得任务数	即梦 赢得任务数	Roboneo 赢得任务数	总任务数
Logo 设计	12	3	3	17
IP 形象设计	7	3	6	16
徽章奖杯设计	12	6	1	19
商品海报设计	5	8	3	16
商品图片美化	6	5	2	13
线上营销活动	12	3	4	18
线下推广物料	10	3	3	16
合计	**64**	**31**	**22**	**115**

附录 F. 场景标准卡（Scenario Cards）

> 参照 HELM 的 Scenario Card 规范，每场景一张标准卡，记录数据来源、任务规模、评测员配置、结果摘要及更新历史，供引用者快速定位场景级信息。

F.1 Logo 设计

字段	内容
场景名	Logo 设计
数据来源	作者原创任务集，虚构品牌"星选"，2025 年起草，2026 年 3 月锁版
任务数量	17 条（模糊 5 / 明确 5 / 编辑 4 / 复合 3）

字段	内容
评测题目数	5 题 × 17 任务 = 85 题
评测员数量	7 人（设计 E01–E05 × 5、研发 E06–E09 × 4，其中 4 人参与本场景）
胜率摘要	Lovart 71% / 即梦 18% / Roboneo 18%
置信度	✅ 高（差距 53%）
备注	职能分歧较大（设计倾向即梦视觉风格，研发倾向 Lovart 执行稳定性），引用时建议注明评测员职能构成
版本	Round 1（2026–03 至 2026–04）

F.2 IP 形象设计

字段	内容
场景名	IP 形象设计
数据来源	作者原创任务集，虚构 IP"萌星"，2025 年起草，2026 年 3 月锁版
任务数量	16 条（模糊 4 / 明确 4 / 编辑 5 / 复合 3）
评测题目数	5 题 × 16 任务 = 80 题
评测员数量	6 人（设计 5、研发 1）
胜率摘要	Lovart 44% / Roboneo 38% / 即梦 19%
置信度	❌ 低（差距 6%，三家产品差距极小）
备注	三家得票差距在误差范围内，建议扩大评测员至 15 人以上后再做定论
版本	Round 1（2026–03 至 2026–04）

F.3 徽章奖杯设计

字段	内容
场景名	徽章奖杯设计
数据来源	作者原创任务集，虚构品牌"星选"，2025 年起草，2026 年 3 月锁版
任务数量	19 条（模糊 5 / 明确 5 / 编辑 5 / 复合 4）

字段	内容
评测题目数	5 题 × 19 任务 = 95 题
评测员数量	7 人（设计 5、研发 2）
胜率摘要	Lovart 63% / 即梦 32% / Roboneo 5%
置信度	✅ 高（差距 31%）
备注	1 道题目存在设计缺陷（"最想珍藏"题），Round 2 将替换；当前结论不含缺陷题数据
版本	Round 1（2026-03 至 2026-04）

F.4 商品海报设计

字段	内容
场景名	商品海报设计
数据来源	作者原创任务集，虚构品牌"星选"，2025 年起草，2026 年 3 月锁版
任务数量	16 条（模糊 4 / 明确 5 / 编辑 4 / 复合 3）
评测题目数	5 题 × 16 任务 = 80 题
评测员数量	6 人（设计 5、研发 1）
胜率摘要	即梦 50% / Lovart 31% / Roboneo 19%
置信度	⚠️ 中（差距 19%，设计职能倾向即梦，研发职能倾向 Lovart）
备注	该场景职能审美偏好分歧明显，建议后续纳入目标用户（消费者）视角评测
版本	Round 1（2026-03 至 2026-04）

F.5 商品图片美化

字段	内容
场景名	商品图片美化
数据来源	作者原创任务集，虚构品牌"星选"，2025 年起草，2026 年 3 月锁版
任务数量	13 条（模糊 3 / 明确 4 / 编辑 4 / 复合 2）

字段	内容
评测题目数	5 题 × 13 任务 = 65 题
评测员数量	6 人（设计 5、研发 1）
胜率摘要	Lovart 46% / 即梦 38% / Roboneo 15%
置信度	❌ 低（差距 8%，源于竞品本身能力接近，非评测员分散）
备注	三家差距偏小源于该场景任务较简单，产品间能力区分度不足；可考虑 Round 2 补充更高难度的编辑型任务
版本	Round 1（2026-03 至 2026-04）

F.6 线上营销活动

字段	内容
场景名	线上营销活动
数据来源	作者原创任务集，虚构品牌"星选"，2025 年起草，2026 年 3 月锁版
任务数量	18 条（模糊 5 / 明确 5 / 编辑 4 / 复合 4）
评测题目数	5 题 × 18 任务 = 90 题
评测员数量	7 人（设计 5、研发 2）
胜率摘要	Lovart 67% / Roboneo 22% / 即梦 17%
置信度	✅ 高（差距 45%）
备注	1 道题目存在设计缺陷（"激发欲望"题），Round 2 将替换；当前结论不含缺陷题数据
版本	Round 1（2026-03 至 2026-04）

F.7 线下推广物料

字段	内容
场景名	线下推广物料

字段	内容
数据来源	作者原创任务集，虚构品牌"星选"，2025 年起草，2026 年 3 月锁版
任务数量	16 条（模糊 4 / 明确 5 / 编辑 4 / 复合 3）
评测题目数	5 题 × 16 任务 = 80 题
评测员数量	7 人（设计 5、研发 2）
胜率摘要	Lovart 63% / 即梦 19% / Roboneo 19%
置信度	✅ 高（差距 44%）
备注	该场景对物料尺寸规格的遵从要求最严，是测试精确执行能力的核心场景；8 道含明确尺寸规格的任务中 Lovart 全部胜出
版本	Round 1（2026-03 至 2026-04）

参考文献


```
@article{liang2022holistic,
  title     = {Holistic Evaluation of Language Models},
  author    = {Liang, Percy and others},
  journal   = {arXiv preprint arXiv:2211.09110},
  year      = {2022}
}

@article{jimenez2024swebench,
  title     = {SWE-bench: Can Language Models Resolve Real-World GitHub Issues?},
  author    = {Jimenez, Carlos E. and others},
  journal   = {ICLR},
  year      = {2024}
}

@article{mialon2023gaia,
  title     = {GAIA: A Benchmark for General AI Assistants},
  author    = {Mialon, Grégoire and others},
```

```
  journal   = {arXiv preprint arXiv:2311.12983},
  year      = {2023}
}

@article{chiang2024chatbot,
  title     = {Chatbot Arena: An Open Platform for Evaluating LLMs by Human Preference},
  author    = {Chiang, Wei-Lin and others},
  journal   = {ICML},
  year      = {2024}
}

@article{srinivas2022drawbench,
  title     = {Photorealistic Text-to-Image Diffusion Models with Deep Language Understanding
  author    = {Saharia, Chitwan and others},
  journal   = {NeurIPS},
  year      = {2022}
}

@article{ghosh2024geneval,
  title     = {GenEval: An Object-Focused Framework for Evaluating Text-to-Image Alignment},
  author    = {Ghosh, Dhruba and others},
  journal   = {NeurIPS},
  year      = {2024}
}

@article{landis1977measurement,
  title     = {The Measurement of Observer Agreement for Categorical Data},
  author    = {Landis, J. Richard and Koch, Gary G.},
  journal   = {Biometrics},
  volume    = {33},
  number    = {1},
  pages     = {159--174},
  year      = {1977}
}

@article{fleiss1971measuring,
  title     = {Measuring Nominal Scale Agreement Among Many Raters},
  author    = {Fleiss, Joseph L.},
  journal   = {Psychological Bulletin},
  volume    = {76},
```

```
  number    = {5},
  pages     = {378--382},
  year      = {1971}
}

@article{hendrycks2020mmlu,
  title     = {Measuring Massive Multitask Language Understanding},
  author    = {Hendrycks, Dan and others},
  journal   = {ICLR},
  year      = {2021},
  note      = {arXiv:2009.03300}
}

@article{chen2021humaneval,
  title     = {Evaluating Large Language Models Trained on Code},
  author    = {Chen, Mark and others},
  journal   = {arXiv preprint arXiv:2107.03374},
  year      = {2021}
}

@inproceedings{yue2024mmmu,
  title     = {{MMMU}: A Massive Multi-discipline Multimodal Understanding and Reasoning Benc
  author    = {Yue, Xiang and others},
  booktitle = {CVPR},
  year      = {2024}
}

@inproceedings{liu2024mmb,
  title     = {{MMBench}: Is Your Multi-modal Model an All-around Player?},
  author    = {Liu, Yuan and others},
  booktitle = {ECCV},
  year      = {2024}
}
```